PROBLEM REZANJA ŠIPKE

empirijska i teorijska analiza algoritma, rekurzivno i dinamičko programiranje



Oblikovanje i analiza algoritama, doc. dr. sc. Matej Mihelčić Prirodoslovno - matematički fakultet, Sveučilište u Zagrebu studeni 2023.

Opis problema

Dana je šipka poznate duljine N, koju je moguće rezati na manje dijelove. Svakoj mogućoj duljini šipke pridružena je vrijednost. Rezanje šipke je besplatno. Potrebno je odrediti optimalan način rezanja šipke, koji će maksimizirati dobit.

Zadani problem potrebno je riješiti rekurzivnim i dinamičkim programiranjem te provesti teorijsku i empirijsku analizu složenosti.

Iako nisu eksplicitno navedeni u opisu problema, uzeto je da vrijede još neki uvjeti kako bi problem bio preciznije definiran ili jednostavniji za implementaciju:

- početna duljina šipke i duljine svih odrezanih dijelova su prirodni brojevi (da bi se problem mogao riješiti rekurzivnim i dinamičkim metodama potrebno je da duljine budu diskretne vrijednosti, a onda je najjednostavnije raditi sa prirodnim brojevima)
- vrijednosti šipki su prirodni brojevi (to je najjednostavnije za implementaciju, a irelevantno za račun složenosti)
- vrijednosti su iz intervala [1, duljina šipke * 1.5] i uniformno su distribuirane (da bismo mogli
 izgenerirati cijene potrebno je zadati neki interval)
- funkcija cijene u ovisnosti o duljini šipke je rastuća (nije eksplicitno navedeno kao pretpostavka, ali je razumno za pretpostaviti)

Algoritamska rješenja

Problem rezanja šipki spada u probleme dinamičkog programiranja i zadovoljava sljedeće principe svojstvene toj skupini problema:

- princip optimalnosti: Da bi šipka određene duljine bila optimalno narezana, "podšipka" koju iz nje dobijemo micanjem najljevijeg dijela također mora biti optimalno narezana.
- princip neovisnosti/invarijantnosti: Optimalan način rezanja preostalog desnog dijela šipke ne ovisi o duljini najljevijeg dijela.
- princip ulaganja/parametrizacije: Problem optimalnog rezanja "poddijelova" početne šipke je iste vrste kao i početni problem rezanja cijele šipke.

Navedene principe koristimo u konstrukciji tri različita algoritma za rješenje problema: rekurziju, memoiziranu rekurziju i bottom-up dinamičko rješenje. Zatim ćemo usporediti operacijsku i vremensku složenost konstruiranih algoritama.

Napomenimo još da u našoj implementaciji nismo pamtili koji način rezanja je optimalan, nego samo koliku maksimalnu vrijednost možemo postići. Za rekonstrukciju rješenja bilo bi potrebno koristiti još jedno polje u koje bismo u svakom koraku spremali izabrane duljine najljevijih dijelova, što bi usporilo program, ali ne bi u konačnici utjecalo na složenost.

Također, u našim rješenjima razlikujemo na primjer particiju šipke 3|5|2 od 2|3|5, što nema smisla, jer za ovaj problem sve permutacije narezanih dijelova u konačnici daju istu vrijednost. Moguće je implementirati i algoritme koji bi to uzimali u obzir, primjerice tako da duljine najljevijih dijelova moraju činiti rastući niz. To bi ubrzalo algoritam, ali bi zakompliciralo račun složenosti, pa to u ovom slučaju nismo napravili.

Primijetimo na kraju da rješenje ovog problema do na poredak permutacija nije jedinstveno te da će naši algoritmi pronaći samo jedno od mogućih rješenja.

Rekurzivno rješenje

Ideja rekurzivnog rješenja je sljedeća: u svakom koraku rekurzije za šipku dane duljine odredimo kolika će biti duljina najljevijeg odrezanog dijela i zatim na ostatak šipke rekurzivno primijenimo isti algoritam. Pritom isprobamo sve moguće duljine najljevijeg dijela i na kraju se odlučimo za onu za koju ćemo ukupno dobiti najveću vrijednost.

```
CUT_ROD(p,n)
    if n == 0
        return 0

    q = -inf
    for i = 1 to n
        q = max{q,p[i] + CUT_ROD(p, n-i)}
    return q
```

Slika 1. – Pseudokod za običan rekurzivni algoritam

Ovo je najočitije rješenje problema, implementacija rekurzivne relacije (1) koju problem zadovoljava, no nedostatak mu je što iste potprobleme rješava mnogo puta.

Memoizirano rekurzivno (top-down) rješenje

Bolji način je koristiti memoizaciju rekurzije, odnosno jednom izračunatu vrijednost funkcije za neku duljinu zapamtiti u memoriji i sljedeći put kad ju zatrebamo, samo pročitati.

Pritom je potrebno na početku algoritma dodatno alocirati i inicijalizirati memoriju za pamćenje podrezultata. Kasnije ćemo vidjeti da ovim postupkom znatno popravljamo vremensku složenost, no to plaćamo potrošnjom memorije (primjer za time-memory trade-off).

```
MEMOIZED CUT ROD(p, n)
    let r[0:n] be a new array
    for i = 0 to n
        r[i] = -inf
    return MEMOIZED_CUT_ROD_AUX(p, n, r)
MEMOIZED_CUT_ROD_AUX(p, n, r)
    if r[n] >= 0
        return r[n]
    if n == 0
       q = 0
    else
        q = -inf
        for i = 1 to n
            q = max{q, p[i], MEMOIZED_CUT_ROD_AUX(p, n-i, r)}
        r[n] = q
        return q
```

Slika 2. – Pseudokod za memoizirani rekurzivni algoritam

Bottom-up dinamički algoritam

Umjesto da krenemo od rješavanja problema za cijelu šipku duljine N te manje potprobleme rješavamo kad nam zatrebaju njihova rješenja, možemo odmah primijetiti da rješavanje "duljeg" problema zahtjeva poznavanje rješenja svih kraćih problema. Zato možemo odmah krenuti od rješavanja najmanjih problema prema većima. Tako ćemo u svakom koraku sva tražena manja rješenja već imati izračunata. Dakle umjesto da problem rješavamo rekurzivno odozgo prema dolje (top-down), rješavamo ga odozdo prema gore (bottom-up).

Kao i za memoiziranu rekurziju, za to nam je potrebna memorija za pamćenje međurezultata, ali je napredak što nemamo puno funkcijskih poziva, koji su vremenski zahtjevni i zauzimaju memoriju na stogu.

```
BOTTOM_UP_CUT_ROD(p, n)

let r[0:n] be a new array

r[0] = 0

for j = 1 to n

q = -inf

for i = 1 to j

q = max{q, p[i] + r[j-i]}

r[j] = q

return r[n]
```

Slika 3. – Pseudokod za bottom-up algoritam

Teorijska analiza

Teorijsku analizu složenosti radimo promatrajući pseudokodove iz prethodnog odlomka.

Za račun složenosti rekurzivnih algoritama najznačajnije je koliko će se puta pozvati funkcija. Zato definiramo:

 $T(n) := broj poziva funkcije CUT_ROD za zadanu početnu duljinu štapa n$ Rekurzivna relacija koja se koristi u rješenju:

$$T(n) = 1 + \sum_{j=0}^{n-1} T(j)$$
 (1)

Uz početni uvjet T(0) = 1.

U formuli (1) broj 1 označava inicijalni poziv funkcije za duljinu n, a članovi sume odgovaraju funkcijskim pozivima unutar for petlje.

To možemo napisati i kao $T(n) = T(n-1) + [T(n-2) + T(n-3) + \cdots + T(2) + T(1)].$ Sada je lakše primijetiti da vrijedi $T(n) = 2 \cdot T(n-1).$

Formulu za rješavanje ove jednostavne rekurzivne relacije dali smo na predavanju:

$$T(n) = 2^n \cdot T(0) = 2^n$$

$$\Rightarrow T(n) \in \theta(2^n)$$

Zaključujemo da rekurzivni algoritma ima eksponencijalnu složenost.

Izračunajmo sada odmah složenost za botttom-up rješenje. U tom rješenju imamo samo jedan funkcijski poziv, ali kao relevantnu operaciju za promatranje složenosti možemo uzeti određivanje maksimuma. Naime, većina operacija će se izvršiti jednom ako su izvan petlji ili n puta ako su unutar vanjske for petlje.

No operacije iz unutarnje for petlje će se izvršiti $1+2+\cdots+n=\frac{n(n+1)}{2}=\frac{n^2}{2}+\frac{n}{2}$ puta, u svakom slučaju. Zaključujemo da je složenost bottom-up rješenja polinomijalna, odnosno $T(n) \in \theta(n^2)$.

Složenost memoiziranog rekurzivnog rješenja je malo teža za vidjeti. Opet promatramo broj poziva funkcije MEMOIZED_CUT_ROD_AUX. Funkcija se inicijalno poziva za duljinu n te se zatim rekurzija spušta u dubinu sve do duljine 1. Zatim se rekurzija krene penjati nazad te u proizvoljnom koraku k u for petlji poziva funkciju MEMOIZED_CUT_ROD_AUX za duljine $1, \dots, k-1$. No sva su ta manja rješenja već ranije izračunata pa sada rekurzije idu samo do dubine 1 (odnosno služe za dohvaćanje zapamćenog rezultata iz memorije). To se najjednostavnije može vidjeti na stablu rekurzije. Dobivamo da je ukupni broj funkcijskih poziva ponovno $1+2+\cdots+n=\frac{n(n+1)}{2}=\frac{n^2}{2}+\frac{n}{2}$, a složenost memoiziranog rekurzivnog rješenja polinomijalna $T(n)\in\theta(n^2)$.

Kao što smo već spomenuli, očekujemo da će usprkos jednakoj složenosti top-down rješenje imati veće konstante, odnosno dulje vrijeme izvršavanja, zbog učestalih funkcijskih poziva.

Empirijska analiza

Mjerenja su izvršavana na računalu sljedećih karakteristika: procesor i7-1165 G7 2.80GHz, 64GB RAM. Inicijalna veličina stoga je 1MB, ali je ta vrijednost za potrebe ovog projekta povećana na 4MB. Program smo implementirali u jeziku C++ i kompajlirali Visual C++ 2019 kompajlerom.

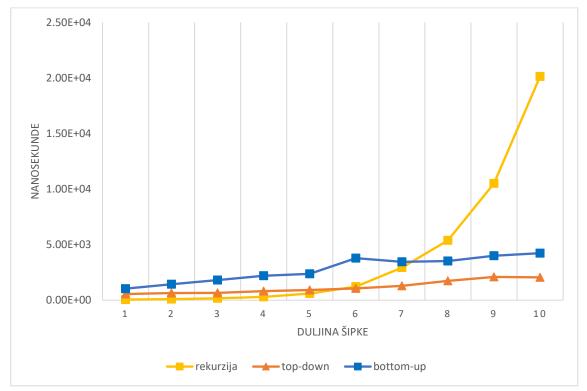
Cijelu implementaciju smo smjestili u jedan program, ali smo kod organizirali tako da se lako može odrediti koji će algoritmi biti pozvani u kojem izvršavanju. Uz to smo u programu koristili sljedeće važne parametre: najmanja i najveća duljina šipke za koju izvršavamo algoritme, korak za koji povećavamo duljinu i broj ponavljanja algoritama za pojedinu duljinu šipke (kako bismo izračunali prosjek vremena izvršavanja i dobili manje oscilacije u mjerenjima).

U izvršenim mjerenjima broj ponavljanja iznosio je 100.

Za manje duljine šipke smo izvršavali sva tri algoritma.

duljina šipke	rekurzija	top-down	bottom-up
1	5.80E+01	5.54E+02	1.04E+03
2	9.90E+01	6.43E+02	1.44E+03
3	1.65E+02	6.64E+02	1.81E+03
4	2.95E+02	8.09E+02	2.20E+03
5	6.01E+02	9.16E+02	2.37E+03
6	1.22E+03	1.06E+03	3.78E+03
7	2.94E+03	1.29E+03	3.46E+03
8	5.39E+03	1.74E+03	3.52E+03
9	1.05E+04	2.09E+03	3.99E+03
10	2.01E+04	2.06E+03	4.23E+03

Tablica 1. – šipke duljine od 1 do 10, povećanje duljine za 1, 100 ponavljanja, mjereno u nanosekundama



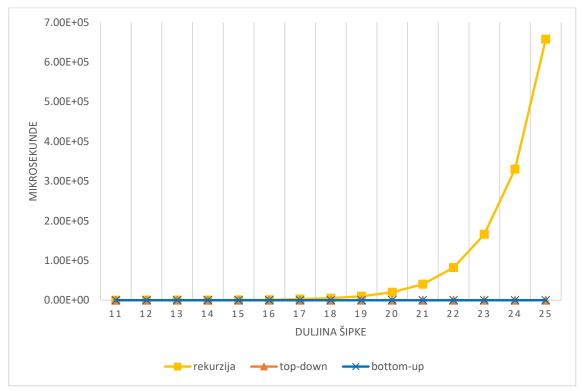
Graf 1. – Ovisnost trajanja izvršavanja algoritama o duljini šipke, prikaz mjerenja iz Tablice 1.

Već se za najmanjih 10 dužina može vidjeti da se oba dinamička algoritma ponašaju relativno slično, dok obična rekurzija odudara. Također primjećujemo da za najmanje dužine rekurzija traje najkraće. Jedan od razloga je što nema potrebe za alokacijom niti inicijalizacijom dodatne memorije. Međutim, vrijeme izvršavanja rekurzije raste znatno brže pa već za duljinu 8 postaje najsporija.

I u narednih 15 mjerenja možemo vidjeti da se sličan trend nastavlja.

duljina šipke	rekurzija	top-down	bottom-up
11	4.64E+01	2.11E+00	3.85E+00
12	8.23E+01	2.33E+00	4.05E+00
13	1.66E+02	2.85E+00	4.24E+00
14	3.27E+02	3.01E+00	4.12E+00
15	6.31E+02	3.09E+00	4.19E+00
16	1.26E+03	3.72E+00	5.49E+00
17	2.56E+03	4.11E+00	8.62E+00
18	5.01E+03	4.15E+00	5.14E+00
19	1.00E+04	5.10E+00	6.13E+00
20	2.01E+04	5.11E+00	6.17E+00
21	4.01E+04	6.34E+00	6.28E+00
22	8.20E+04	6.41E+00	6.50E+00
23	1.66E+05	7.17E+00	7.12E+00
24	3.30E+05	8.09E+00	7.37E+00
25	6.58E+05	8.43E+00	1.15E+01

Tablica 2. – šipke duljine od 11 do 25, povećanje duljine za 1, 100 ponavljanja, mjereno u mikrosekundama



Graf 2. – Ovisnost trajanja izvršavanja algoritama o duljini šipke, prikaz mjerenja iz Tablice 2.

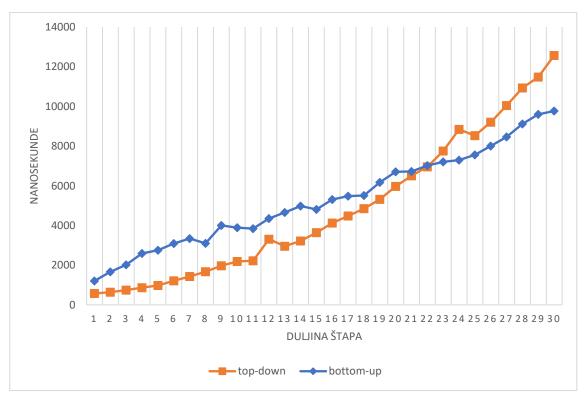
U preostalim mjerenjima nećemo više promatrati običnu rekurziju, jer bi nam njeno izvršavanje za veće duljine previše usporilo mjerenje, a na grafu ne bismo mogli uspoređivati ponašanje dinamičkih algoritama.

Najprije ponovimo mjerenja za duljine 1 - 30. Sada jasno vidimo da rekurzivno rješenje na početku ima manje vrijeme izvršavanja, ali je porast trajanja veći i oko duljine 22 taj algoritam postaje sporiji.

duljina šipke	top-down	bottom-up
1	5.74E+02	1.21E+03
2	6.37E+02	1.66E+03
3	7.43E+02	2.02E+03
4	8.63E+02	2.59E+03
5	9.81E+02	2.75E+03
6	1.22E+03	3.09E+03
7	1.43E+03	3.34E+03
8	1.67E+03	3.10E+03
9	1.97E+03	4.00E+03
10	2.19E+03	3.89E+03
11	2.22E+03	3.84E+03
12	3.31E+03	4.35E+03
13	2.96E+03	4.66E+03
14	3.22E+03	4.98E+03
15	3.64E+03	4.81E+03
16	4.12E+03	5.31E+03
17	4.48E+03	5.48E+03
18	4.85E+03	5.51E+03
19	5.32E+03	6.18E+03

20	5.97E+03	6.71E+03
21	6.51E+03	6.72E+03
22	6.96E+03	7.02E+03
23	7.76E+03	7.21E+03
24	8.85E+03	7.29E+03
25	8.53E+03	7.56E+03
26	9.21E+03	8.01E+03
27	1.00E+04	8.47E+03
28	1.09E+04	9.12E+03
29	1.15E+04	9.61E+03
30	1.26E+04	9.77E+03

Tablica 3. – šipke duljine od 1 do 30, povećanje duljine za 1, 100 ponavljanja, mjereno u nanosekundama



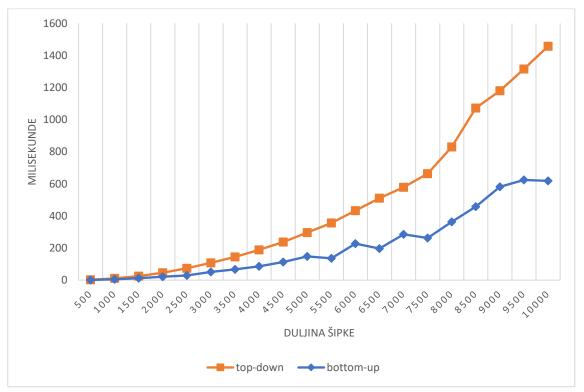
Graf 3. – Ovisnost trajanja izvršavanja algoritama o duljini šipke, prikaz mjerenja iz Tablice 3.

Obzirom na vrijeme izvršavanja izmjereno u nanosekundama, zaključujemo da ove algoritme možemo izvesti i za znatno dulje štapove U sljedećem mjerenju krenuli smo s početnom duljinom 500 i uz korak 500 došli do duljine od 10 000. Trajanje smo ovaj put mjerili u milisekundama. Pritom je bilo potrebno povećati inicijalnu veličinu stoga od 1MB na 4MB, jer je zbog dubine rekurzije došlo do stack overflowa.

duljina šipke	top-down	bottom-up
500	2.13E+00	1.00E+00
1000	1.11E+01	5.02E+00
1500	2.55E+01	1.19E+01
2000	4.63E+01	2.14E+01
2500	7.40E+01	2.90E+01
3000	1.08E+02	5.08E+01

3500	1.44E+02	6.68E+01
4000	1.88E+02	8.62E+01
4500	2.38E+02	1.13E+02
5000	2.96E+02	1.47E+02
5500	3.56E+02	1.36E+02
6000	4.33E+02	2.28E+02
6500	5.11E+02	1.97E+02
7000	5.79E+02	2.86E+02
7500	6.63E+02	2.63E+02
8000	8.30E+02	3.64E+02
8500	1.07E+03	4.58E+02
9000	1.18E+03	5.81E+02
9500	1.32E+03	6.24E+02
10000	1.46E+03	6.19E+02

Tablica 4. – šipke duljine od 500 do 10 000, povećanje duljine za 500, 100 ponavljanja, mjereno u milisekundama



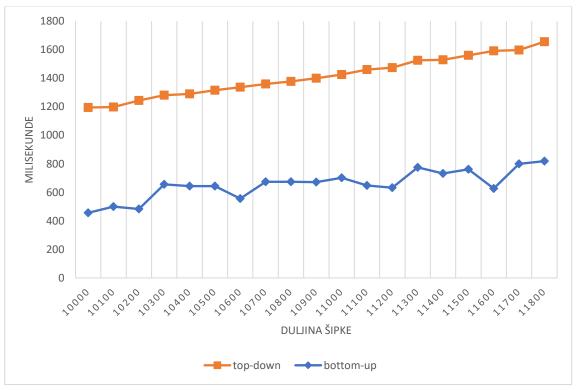
Graf 4. – Ovisnost trajanja izvršavanja algoritama o duljini šipke, prikaz mjerenja iz Tablice 4.

Na ovom je grafu već jasno vidljivo da porast vremena izvršavanja nije linearan ni za jedno od rješenja te da trajanje memoizirane rekurzije raste brže.

Na kraju smo još željeli vidjeti do koje duljine šipke, odnosno dubine rekurzije, možemo doći sa alociranih 4MB RAM-a. Eksperimentalno smo dobili da se za duljinu 11 800 algoritmi izvršavaju, dok za duljinu 11 900 dobivamo grešku sa kodom -1073741571, što označava "stack overflow". Navodimo rezultate i tih mjerenja. Kako nam ova mjerenja nisu bila posebno zanimljiva za promatranje složenosti, za svaku smo duljinu mjerenje ponovili 3 puta.

duljina štapa	top-down	bottom-up
10000	1.19E+03	4.56E+02
10100	1.20E+03	5.00E+02
10200	1.24E+03	4.83E+02
10300	1.28E+03	6.55E+02
10400	1.29E+03	6.43E+02
10500	1.32E+03	6.44E+02
10600	1.34E+03	5.56E+02
10700	1.36E+03	6.73E+02
10800	1.38E+03	6.74E+02
10900	1.40E+03	6.71E+02
11000	1.43E+03	7.02E+02
11100	1.46E+03	6.48E+02
11200	1.47E+03	6.32E+02
11300	1.53E+03	7.75E+02
11400	1.53E+03	7.32E+02
11500	1.56E+03	7.61E+02
11600	1.59E+03	6.27E+02
11700	1.60E+03	7.99E+02
11800	1.66E+03	8.19E+02

Tablica 5. – šipke duljine od 10 000 do 11 800, povećanje duljine za 100, 3 ponavljanja, mjereno u milisekundama



Graf 5. – Ovisnost trajanja izvršavanja algoritama o duljini šipke, prikaz mjerenja iz Tablice 5.

Izvori

- Cormen, T. H., Leiserson, C. E., Rivest, R. L., & Stein, C. (2022). Introduction to Algorithms (Fourth Edition). MIT Press. https://mitpress.mit.edu/algorithms/
- 2. Mihelčić, M. 30.10.2023. "Dinamičko programiranje nastavak, pohlepni algoritmi uvod". kolegij Oblikovanje i analiza algoritama. Prirodoslovno matematički fakultet, Sveučilište u Zagrebu https://web.math.pmf.unizg.hr/nastava/oaa/materijali/predavanjaMM/Predavanje6.pdf